企業破產預測與信用風險辨識

機器學習與深度學習專題企劃說明書

本專題使用 data.csv 的企業財務指標與破產標籤，建立企業風險辨識模型，比較傳統機器學習與深度學習方法，並分析資料處理、類別不平衡、特徵選擇及判定門檻如何影響結果。

研究同時重視預測能力與財務解釋：除了找出表現較好的模型，也要說明模型依據哪些資訊判斷、容易在哪些情況出錯，以及結果能如何應用。最終成果預計包含可重現的分析流程、模型比較報告、視覺化圖表與互動展示網站。

本企劃中的資料筆數、標籤比例與資料品質問題，來自現有檔案檢查；模型績效、重要變數排名與研究結論，須由後續實驗產生。

研究資料	執行環境	研究設計
僅使用目前的 data.csv	付費版 Google Colab	核心必做＋進階選做

閱讀指引： 第一至三節說明目標、資料與研究範圍；第四至九節說明資料處理、模型與評估；第十至十二節說明解釋、網站及成果；第十三至十四節說明能力養成與現金股利預測的延伸。

01 研究目標與問題

本專題以企業破產風險辨識為研究目標。我們希望回答：「從企業財務指標中，能否辨識出較可能具有破產標籤的樣本？哪些方法能在找出高風險樣本的同時，控制誤報？」

這個問題的困難在於破產樣本很少。模型可能只要一直預測「未破產」，就取得很高的準確率，卻完全沒有辨識風險的能力。因此，研究重點包括：

- 比較模型能力： 傳統模型與深度學習模型，在這份表格資料上的表現有何差異？
- 比較資料處理方法： 類別權重、過採樣及特徵精簡，是否能改善破產樣本的辨識？
- 分析實際取捨： 提高破產召回率時，需要增加多少誤報？
- 理解模型判斷： 哪些財務指標影響預測？這些影響是否穩定、是否符合合理的財務解讀？
- 完成可操作成果： 能否將訓練完成的流程整合到網站，讓使用者查看預測、模型解釋與限制？

研究定位是歷史資料中的風險辨識與方法比較。由於現有資料缺少預測基準日與事件時間，研究結果不能直接解讀為企業「未來一年破產的機率」。

02 資料集簡介與已知品質問題

本專題只使用目前提供的 data.csv，不另外加入其他資料集進行訓練。以下筆數與品質檢查結果來自該檔案。

項目	現有資料概況
觀測筆數	6,819 筆
欄位數量	96 欄，包含 95 個特徵與 1 個目標欄位
目標欄位	Bankrupt?
標籤定義	0 為未破產標籤；1 為破產標籤
未破產樣本	6,599 筆，約 96.77%
破產樣本	220 筆，約 3.23%
欄位型態	全部為數值型態，但部分欄位實際上是二元旗標
缺失與重複	未發現缺失值、無限值或完全重複的資料列
時間與識別資訊	沒有可直接使用的公司識別碼、年度或事件日期

資料內容對應 UCI 的 Taiwanese Bankruptcy Prediction 資料集。該資料集說明指出，資料來自台灣經濟新報資料庫，涵蓋 1999 至 2009 年，破產標籤依台灣證券交易所相關業務規則定義。企劃沿用資料來源的標籤意義，避免自行擴大解釋為所有法律或授信情境中的違約。[1]

財務特徵可以先用以下方式理解：

財務面向	指標例子	希望觀察的問題
獲利能力	資產報酬率、營業毛利率	企業是否具備持續獲利能力？
負債與資本結構	負債比率、淨值占資產比率	財務結構是否承受較高負債壓力？
短期償債能力	流動比率、速動比率	短期資源是否足以支應短期負債？
現金流量	現金流量相關比率	帳面獲利是否伴隨現金流入？
經營效率	資產週轉相關指標	資產運用是否有效率？

這些分類是理解資料的起點，不代表尚未訓練模型就能確定哪些指標最重要。

現有檔案也有幾項需要處理的問題：

- 部分欄位名稱含前後空白，應統一清理。
- Net Income Flag 全部為同一數值，無法區分樣本。
- 有兩組完全重複的特徵，例如 Current Liabilities/Liability 與 Current Liability to Liability。
- Debt ratio % 與 Net worth/Assets 在檔案中完全互補，對含截距的線性模型會形成完全共線性，可保留其中一個。
- 並非所有特徵都落在 0 至 1 之間。共有 24 個特徵超出此範圍，部分數值非常大，例如 Current Ratio 的最大值為 27.5 億。

因此，不能直接假設所有欄位都已妥善標準化，也不能在缺少轉換說明時，把某個數值直接解讀為原始財務百分比。異常尺度應先查核與記錄，再安排處理方式及敏感度比較。

03 核心必做與進階選做

核心部分建立完整且可信的研究流程；進階部分依核心結果選擇，避免方法過多而無法清楚解釋每項實驗的目的。

範圍	預計內容
核心資料分析	資料品質檢查、類別比例、特徵分布、相關性分析
核心模型	Elastic Net Logistic Regression、Random Forest、XGBoost、Balanced Random Forest、MLP、FT-Transformer
基準模型	Dummy Classifier
核心方法比較	類別權重、代表性過採樣實驗、完整與精簡特徵比較
核心評估	AP、PR 曲線、Recall、Precision、F1、混淆矩陣、ROC-AUC、成本情境
預測可靠性	機率校準、校準曲線、Brier Score、不同隨機種子的穩定性

範圍	預計內容
財務解釋	SHAP、財務面向整理、正確與錯誤案例分析
成果展示	Colab 分析流程、研究報告、互動網站
進階選做	額外表格深度學習模型、進階抽樣、降維、模型融合、巢狀交叉驗證

進階實驗原則上選擇一至兩個最能回答研究問題的方向。例如，若深度學習表現不穩定，可優先研究正則化與訓練穩定性；若模型容易誤報，則優先研究門檻與機率校準。

04 資料切分與驗證設計

資料切分與驗證方式，必須先於模型比較確定。本專題建議先保留約 20% 的分層測試集，其餘約 80% 作為開發集。

分層切分會盡量維持兩類樣本比例。依目前資料量估算，測試集約有 1,364 筆，其中約 44 筆為破產樣本；開發集約有 5,455 筆，其中約 176 筆為破產樣本。

開發集使用分層五折交叉驗證。每次以其中四折訓練、一折驗證，讓各模型在相同切分下比較。模型設定、特徵選擇、處理方法與判定門檻，都在開發階段決定。

實驗流程遵守以下原則：

- 測試集保留至最後。 模型與評估方案確定後，才進行最終測試；不依測試結果反覆修改模型。
- 需要從資料學習的處理，都在訓練折內完成。 包括標準化、截尾門檻、特徵選擇與過採樣。
- 深度學習的早停也使用訓練資料內部分出的驗證資料。 不以最終測試集決定訓練輪數。
- 校準與門檻選擇使用開發集中的獨立驗證資料或交叉驗證預測。 不直接使用模型對自身訓練資料的預測。
- 各模型共享資料切分，但採用適合自己的處理方式。 例如線性模型需要考慮尺度，樹模型通常不需要同樣的縮放流程。

這些安排的目的是避免資料洩漏。例如，先對整份資料執行 SMOTE，再切出測試集，會讓測試樣本與訓練中的合成樣本產生不當關聯，使結果過度樂觀。[2][3]

由於目前缺少公司識別碼與時間欄位，無法確認不同資料列是否來自同一公司，也無法執行真正的跨年度驗證。因此，本專題的結果主要反映目前資料分布下的辨識能力。

05 資料處理與特徵工程

資料處理以可解釋、可比較及避免洩漏為原則。每項處理都需要說明目的，並保留未使用該處理的比較版本。

首先，建立資料字典與品質檢查紀錄。資料字典至少包含欄位名稱、可能的財務意義、數值範圍、是否為旗標，以及目前無法確認的尺度資訊。原始檔案保留不變，清理流程由程式重現。

目前沒有缺失值，因此不需要為了增加方法數量而加入補值步驟。未來若網站收到缺少必要欄位的輸入，應清楚提示，不應直接補成零。

探索性資料分析以開發集為主，預計包含：

- 破產與未破產樣本的數量及比例。
- 各特徵的分位數、直方圖與箱型圖。
- 兩類樣本在主要財務指標上的分布差異。
- Pearson 與 Spearman 相關性，用來檢查線性關係與單調關係。
- 極端值、稀有旗標及高度相關特徵的整理。

這些圖表用來形成待驗證的假設。例如，若某項負債指標在兩類樣本中分布不同，可以進一步檢查它是否對預測有幫助，但不能只憑圖形就推論因果。

方法	為什麼考慮使用	本專題的使用方式
移除常數與重複特徵	減少沒有辨識資訊或重複的欄位	依明確檢查規則處理，記錄保留與移除項目
StandardScaler	避免尺度差異影響線性模型與神經網路訓練	作為 Logistic Regression、MLP 等模型的候選處理
RobustScaler	使用中位數與四分位距縮放，降低極端值對縮放參數的影響	與一般標準化進行受控比較
分位數截尾	限制極端數值對部分模型的影響	比較不截尾與訓練資料分位數截尾版本
相關性篩選	減少高度重複的資訊	在訓練折內計算，再依規則選擇代表特徵
Elastic Net 特徵精簡	同時考慮稀疏性與係數穩定性	與完整特徵版本比較效能、穩定性及解釋難度

RobustScaler 只改變尺度，不會自動把極端值刪除，也不會保證資料變成常態分布。[4]

極端值處理尤其需要謹慎。財務困難企業可能本來就具有極端指標，直接刪除可能移除最有價值的破產訊號。若無法確認異常值是資料錯誤，應比較不同處理下的結果，並揭露不確定性。

進階可考慮 Yeo-Johnson 轉換、分位數轉換、互資訊特徵選擇或 PCA。其中 PCA 適合研究降維是否有助於預測，但主成分較難直接對應原始財務指標，因此需要同時評估解釋上的代價。

此外，現有欄位可能已經過不同形式的轉換。在缺乏原始尺度資訊時，不宜再任意相除，並把結果命名為新的財務比率。

06 類別不平衡處理

類別不平衡處理需要同時觀察召回率與誤報。本資料的破產樣本約占 3.23%，模型容易偏向未破產類別，因此需要安排專門的比較實驗。

方法	原理	希望觀察的結果
不進行平衡處理	直接使用原始類別分布訓練	建立比較起點

方法	原理	希望觀察的結果
類別權重	提高破產樣本在損失函數中的影響	是否能增加破產召回率，以及增加多少誤報
過採樣	增加訓練資料中少數類別的出現頻率或合成樣本	是否能改善模型學習到的分類邊界

類別權重依訓練資料估計，並在開發集比較不同設定。權重越大不代表越好，過大的權重可能讓模型把大量未破產樣本判成高風險。

過採樣可先比較 Random Oversampling，再視特徵型態考慮 SMOTE 或 SMOTENC。現有資料包含二元旗標，例如 Liability-Assets Flag；若保留這類欄位，一般 SMOTE 可能產生介於 0 與 1 之間的合成旗標，因此 SMOTENC 更適合混合連續數值與類別欄位的情境。[5]

不過，SMOTENC 保留類別取值，並不代表所有合成樣本都具有合理的財務關係。仍應檢查生成資料的範圍、比例及模型效果。若連續特徵尺度差異很大，距離式過採樣也需在訓練折內安排合適的縮放。

實驗不預設一定要把兩類補成 1：1，也不一開始就同時疊加大量過採樣、強類別權重與 Focal Loss。先單獨比較，才能知道改善來自哪個方法。

進階可選擇 SMOTE-Tomek、SMOTE-ENN、Borderline-SMOTE 或 Focal Loss。若使用會移除樣本的方法，需記錄各類別被移除的數量，避免清理過程反而刪掉重要的少數類別案例。

07 核心模型與進階模型

核心模型涵蓋可解釋模型、樹模型與深度學習模型。每種模型都對應不同的研究目的，而不是只增加模型數量。

模型	基本原理	本專題中的角色與注意事項
Dummy Classifier	使用固定規則預測，例如全部判為未破產	建立最低比較基準，說明高 Accuracy 不代表能辨識破產
Elastic Net Logistic Regression	用財務特徵的加權組合預測二元結果，結合 L1 與 L2 正則化	作為可解釋基準，觀察係數方向、特徵精簡與穩定性
Random Forest	訓練多棵決策樹，再整合預測	學習非線性與特徵交互作用，作為穩健的樹模型比較對象
XGBoost	逐步加入新樹，修正目前模型的預測誤差	檢驗梯度提升樹在此資料上的辨識能力
Balanced Random Forest	每棵樹使用經過類別平衡抽樣的資料訓練	與一般 Random Forest 比較，分析內建平衡抽樣的效果
MLP	透過多層全連接網路學習非線性特徵組合	作為基礎深度學習模型，研究容量、正則化與類別權重

模型	基本原理	本專題中的角色與注意事項
FT-Transformer	將各特徵轉為表徵，再以注意力機制學習特徵間的關係	檢驗專為表格資料設計的深度學習方法是否帶來改善

Elastic Net Logistic Regression 的價值在於建立清楚的比較基準。 L1 正則化能讓部分係數變為零，形成較精簡的模型；L2 正則化則有助於控制係數大小，處理相關特徵帶來的不穩定。其限制是原始形式較難直接表達複雜非線性關係。係數方向可以輔助理解模型，但不能直接當作因果效果。

Random Forest 與 XGBoost 用來研究非線性財務關係。 例如，某個負債指標的風險意義，可能取決於企業的現金流或獲利狀況。樹模型能學習這類交互作用，但仍須控制樹深度、葉節點規模與模型複雜度，避免過度擬合。

Balanced Random Forest 用來單獨檢驗抽樣策略。 它在訓練各棵樹時使用平衡後的樣本，可能增加對少數類別的敏感度，但也可能提高誤報，因此需要與一般 Random Forest 同時比較 Recall、Precision 與成本。[6]

MLP 使用較小的網路作為起點。 本資料量有限，初期不追求很深的架構，而是透過 Dropout、權重衰減與 Early Stopping 控制過度擬合。訓練時比較一般二元交叉熵與加權損失，並觀察訓練與驗證曲線是否明顯分離。

FT-Transformer 的注意力作用於欄位之間。 它可以學習不同財務指標如何共同影響預測，不需要把資料當成時間序列。研究上應將它與 MLP、XGBoost 一起比較，而非預設 Transformer 一定較好；相關研究也強調表格深度學習與梯度提升樹之間不存在普遍適用的單一贏家。[7]

若核心實驗完成，可從以下方向挑選進階模型：

進階方法	適合研究的問題
TabNet	逐步選擇特徵的注意力機制，是否能提供有用的預測與解釋？
TabM	以較有效率的神經網路集成方式，是否能改善 MLP 的表現與穩定性？
Denoising Autoencoder＋分類器	先學習較精簡、抗擾動的表徵，是否有助於分類？
Explainable Boosting Machine	較容易呈現單一特徵影響的模型，能否兼顧表現與解釋？
Stacking	不同模型的預測是否具有互補資訊？

TabNet 與 TabM 分別代表注意力式表格學習及參數效率較高的神經網路集成方向，適合作為不同研究假設的延伸。[8][9]

若使用 Stacking，第二層模型必須學習第一層模型的交叉驗證預測，避免直接使用第一層模型對自身訓練資料的預測而造成過度樂觀。Autoencoder 的表徵學習也需限制在訓練資料內。

08 實驗矩陣與比較方式

實驗安排以回答問題為單位，避免所有方法任意排列組合。建議依下列順序執行：

實驗	主要比較	回答的問題
基準實驗	Dummy 與未平衡的 Logistic Regression	單純基準能做到什麼程度？
核心模型比較	六個核心模型	不同模型家族的能力與成本有何差異？
不平衡處理比較	代表性模型的不處理、類別權重與過採樣版本	改善是否來自類別平衡策略？
特徵精簡比較	完整清理後特徵與精簡特徵	是否能用較少特徵維持表現？
門檻與校準比較	原始分數、校準結果與不同判定門檻	預測是否可靠？不同取捨會如何影響決策？
穩定性比較	入選模型使用不同隨機種子重複訓練	表現是否依賴某一次幸運訓練？

特徵精簡與處理方法比較可先集中在表現較好的傳統模型與深度學習模型，不必要求每個模型都跑遍所有組合。

每次實驗記錄資料切分、處理方法、模型設定、隨機種子、訓練時間與評估結果。報告也應揭露各模型獲得的調參機會，避免把大量調整過的模型與幾乎未調整的模型視為完全公平的比較。

進階可對入選模型使用巢狀交叉驗證：內層選設定，外層估計整個選模流程的表現，以降低調參造成的評估偏差。[10]

09 評估指標、門檻與預測可靠性

評估同時涵蓋排序能力、分類結果、機率可靠性與決策成本。本專題固定以破產標籤 1 為正類。

實際狀態	預測為破產	預測為未破產
實際為破產	TP：成功辨識	FN：漏掉破產樣本
實際為未破產	FP：誤報風險	TN：正確排除

本資料若全部預測為未破產，Accuracy 仍約為 96.77%，但破產 Recall 為零。因此，Accuracy 只作輔助資訊。

指標	回答的問題	解讀方式
AP（Average Precision）	模型能否把破產樣本排在較前面？	作為主要排序指標，越高越好

指標	回答的問題	解讀方式
Recall	真正的破產樣本中，找出多少？	TP ÷（TP＋FN）
Precision	被判為破產的樣本中，多少是真的？	TP ÷（TP＋FP）
F1-score	Precision 與 Recall 是否取得平衡？	比較特定門檻下的分類結果
ROC-AUC	模型整體區分兩類的排序能力如何？	與 AP 一起看，不單獨代表實務效果
MCC	綜合四種分類結果後，預測與標籤有多一致？	作為不平衡分類的補充指標
Recall@Top 10%	若只能檢查風險最高的 10% 樣本，能找出多少破產案例？	對應有限審查資源的情境
Brier Score、Log Loss	預測機率與實際結果是否相符？	搭配校準曲線判讀，數值越低越好

AP 與使用梯形積分計算的 PR 曲線面積並不完全相同。正式報告應明確標示使用哪種計算方式；本企劃以 AP 作為主指標，並另外呈現 PR 曲線。[11]

Recall@Top 10% 也可以搭配 Lift。例如，假設風險最高的 10% 樣本包含全部破產案例的 60%，則 Lift 為 6。這只是解讀示例，實際數值須由實驗計算。

判定門檻不固定使用 0.5，而依開發集中的目標選擇，例如：

- 在可接受的誤報率下，提高破產 Recall。
- 在有限的審查名額下，優先找出更多破產樣本。
- 在指定成本情境下，降低整體錯誤成本。

門檻選擇需要獨立驗證或交叉驗證資料；若直接用訓練結果調門檻，容易高估效果。正式測試時，應使用開發階段已確定的門檻。[12]

成本分析採用假設性的相對成本：

情境	漏判破產 FN 的成本	誤報 FP 的成本
情境一	5	1
情境二	10	1
情境三	20	1

以情境二為例，總成本為「10 × FN ＋ FP」，也可除以樣本數，方便比較。這些比例用來研究不同取捨，不能當作真實金額損失；現有資料沒有授信金額、違約損失率等資訊。

機率可靠性方面，類別權重與過採樣可能改變模型分數的機率意義。因此，對需要展示機率的模型，安排校準曲線與校準實驗。校準資料保留原始類別比例，並優先考慮較簡單的方法；更有彈性的 Isotonic

Calibration 在樣本較少時需要留意過度擬合。Brier Score 與 Log Loss 也同時受到辨識能力等因素影響，不能只用單一數字判定校準是否良好。[13]

最後，報告應呈現不確定性。測試集若只有約 44 個破產樣本，多找出或漏掉 1 個，就會使 Recall 改變約 2.27 個百分點。因此，入選模型可使用不同隨機種子重複訓練，並對固定測試預測進行配對 Bootstrap，估計指標或模型差異的信賴區間。這類估計仍依賴樣本獨立性假設，無法消除缺少公司識別碼造成的限制。

AIC、BIC、HQIC 不列為樹模型與神經網路之間的主要排名依據；若保留，只用於符合其統計假設、可合理定義似然與參數數量的模型比較。

10 模型解釋與財務分析

模型解釋應連結財務意義，也應呈現錯誤案例。本專題使用 SHAP 分析特徵如何影響模型預測，並搭配財務面向整理。

整體解釋預計包含：

- 特徵重要性圖：觀察哪些欄位對模型輸出影響較大。
- SHAP 分布圖：觀察高值、低值與預測方向的關係。
- 代表性特徵關係圖：觀察模型是否學到非線性或條件式關係。
- 不同切分或隨機種子下的重要性比較：檢查解釋是否穩定。

個別解釋則選擇成功辨識、漏判、誤報與正確排除的案例，說明哪些資訊推高或降低模型分數。案例選擇應有明確規則，避免只展示模型成功的樣本。

解讀時需要注意：

- 重要性高不代表具有因果效果。 SHAP 解釋的是模型如何使用資訊，不能證明改變某個財務指標就會使企業避免破產。
- 高度相關特徵可能分攤貢獻。 可同時從負債、獲利、償債與現金流等財務面向解讀。
- 數值尺度需要標示。 若無法還原原始財務單位，應使用資料欄位尺度描述。
- 解釋必須對應實際展示的模型輸出。 若 SHAP 解釋的是校準前分數，不能直接把貢獻值寫成校準後機率的百分點。

SHAP 對樹模型的輸出尺度可能是原始分數或機率；例如部分 XGBoost 分類模型的原始輸出為 log-odds，正式圖表需要標示清楚。[14][15]

財務討論應以結果為依據。例如，若某個負債指標在多次實驗中都具有穩定影響，再討論其可能代表的財務壓力；不在實驗前預先寫定重要變數排名。

11 互動網站與成果展示

互動網站將研究成果轉為可操作的展示。模型開發使用付費版 Google Colab，網站可使用 Streamlit 建置。Colab 負責分析與訓練，網站負責載入已保存的流程並執行推論；正式展示需要另行安排可持續運作的部署環境。

功能	內容
專題與資料介紹	說明問題、資料來源、標籤定義及使用限制
模型比較	展示實際實驗指標、PR 曲線與混淆矩陣
範例選擇	讓使用者選取代表性資料列，查看分數與解釋
CSV 上傳	接受符合訓練資料規格的檔案，進行批次預測
預測結果	顯示資料列識別、風險分數、排序及固定門檻下的分類
個別解釋	顯示支援的模型解釋與主要影響特徵
結果下載	匯出預測結果與模型版本資訊

上傳檔案時，網站應檢查必要欄位、名稱、數值型態、缺失與異常輸入。目標欄位 Bankrupt? 不作為預測特徵，也不要求使用者事先提供答案。

網站必須載入訓練時保存的前處理、模型、校準器與門檻，不重新用上傳檔案訓練縮放器或調整模型。相同輸入在 Colab 與網站上應得到一致結果。

由於現有資料的轉換方式未完全明確，網站主要定位為研究展示。一般企業的原始財報數字，不能在未完成相容轉換的情況下直接輸入。介面宜優先使用範例與相容 CSV，而非讓使用者任意調整所有欄位。

如果展示高、中、低風險分組，分組規則應在開發階段先定義，例如依排序比例設定，並說明它代表資料集內的相對風險。

12 階段成果、重現與驗收

專題以階段成果與驗收條件管理進度。各階段完成後，都應留下可檢查、可重現的輸出。

階段	工作內容	可檢查成果
資料理解	品質檢查、資料字典、探索分析	欄位說明、問題紀錄、分布與相關性圖表
基準建立	固定切分、建立基準與六個核心模型	可執行的 Colab 流程、初步比較表
方法比較	不平衡處理、特徵精簡、必要的進階實驗	控制條件清楚的實驗紀錄
最終評估	凍結方案、測試集評估、穩定性與解釋	指標表、PR 曲線、校準圖、成本分析與案例
成果整合	網站、操作說明與研究報告	可展示系統、模型檔案、完整報告

為了能重現結果，應保存資料版本、切分索引、隨機種子、套件版本、處理規則、模型設定及預測輸出。深度學習模型也需保存權重與訓練紀錄，避免 Colab 工作階段結束後遺失重要成果。

完成標準包括：

- 六個核心模型與基準模型皆有可追溯的實驗結果。
- 比較流程沒有明顯資料洩漏，測試集未被反覆用來調參。
- 能說明模型如何改善破產辨識，以及伴隨的誤報與成本。
- 能解釋代表性成功與失敗案例。
- 網站推論與分析程式一致，輸入檢查與操作說明完整。
- 結論忠實反映結果，包括沒有改善或表現不穩定的方法。

不預先承諾特定 AUC 或 Recall。即使 FT-Transformer 沒有超越 XGBoost，只要比較公平、結果可重現，且能分析可能原因，仍然是有價值的研究成果。

13 能力養成與學習效益

這份專題可以訓練從資料到應用的完整能力。學習成果不只在於會呼叫模型，而是能為每個步驟提出理由、設計比較並解讀證據。

能力	在本專題中的練習	未來可應用的方向
問題與標籤定義	確認破產標籤的意義與可回答範圍	現金股利、違約、流失等分類問題
財務資料理解	整理指標、尺度、重複資訊與異常值	財報分析與金融資料品質管理
特徵處理	縮放、特徵選擇與敏感度分析	其他結構化資料建模
機器學習與深度學習	比較線性模型、樹模型及神經網路	依資料特性選擇方法
不平衡分類	比較權重、抽樣與門檻	詐欺、設備故障、稀有事件偵測
實驗設計	切分、交叉驗證與避免洩漏	建立可信的預測研究
評估與決策	分析漏判、誤報、成本與校準	將模型結果連結實際使用需求
解釋與溝通	將 SHAP 與錯誤案例轉為可理解的說明	向業務或非技術使用者解釋模型
工程與重現	保存流程、版本與推論系統	將分析成果整合成可用工具

14 延伸應用：預測是否發放現金股利

現金股利預測是這套研究流程的具體延伸。未來可以把研究問題改為：「在某個預測基準日，使用當時已公開的公司資訊，預測該公司在之後十二個月內是否實際發放現金股利。」

這個任務可以沿用本專題的研究流程，但需要另外準備資料、建立標籤並重新訓練模型。不能直接把破產模型的輸出改名為股利預測。此項僅為未來應用說明，現階段實驗仍只使用目前的 data.csv。

項目	股利預測的設計示例
預測單位	某公司在某個預測基準日
正類標籤 1	後續指定期間內實際發放現金股利，金額大於零
負類標籤 0	確認該期間內未發放現金股利
資料不足	不直接當成 0；需補齊、排除或另外處理
可用特徵	預測基準日前已公開、當時可取得的資訊

資料可能包含獲利能力、營業現金流、現金持有、保留盈餘、負債程度、公司規模與過去股利紀錄。這些是候選特徵，是否有用仍需實驗驗證。

這個延伸尤其能練習以下判斷：

- 區分財報所屬期間與實際公告日期。 某年度的財報可能隔年才公布，預測時只能使用當時已知的資訊。
- 避免使用已揭露答案的欄位。 若公司已公告本次現金股利，再用該資訊預測是否配息，就失去事前預測意義。
- 保留公司與時間識別。 需要公司代碼、財報公告日期、股利事件與發放日期，才能正確對齊特徵與標籤。
- 採用符合應用情境的驗證。 例如以前期資料訓練、後期資料測試；若目標是預測從未見過的公司，再安排公司群組切分。
- 重新評估類別比例與錯誤成本。 配息公司不一定是少數類別，不能直接沿用破產任務的抽樣比例與權重。
- 確保結果已完整觀察。 尚未走完預測期間的樣本，不能提前判定為未配息。

可沿用的資產包括資料檢查方式、前處理架構、模型比較流程、評估方法、解釋工具與網站設計；需要重新建立的部分則包括標籤、資料時間對齊、模型參數、校準方式及判定門檻。

完成本專題後，組員應能把一個財務問題整理成可驗證的預測任務，判斷哪些資訊在預測當下可用，建立公平的比較，並清楚說明模型的能力、錯誤與適用範圍。

參考資料

資料筆數與品質檢查以使用者提供的 data.csv 為準。下列資料集說明、官方文件與研究論文，提供方法與評估設計的依據。

[1] UCI Machine Learning Repository. Taiwanese Bankruptcy Prediction.
https://archive.ics.uci.edu/dataset/572/taiwanese+bankruptcy+prediction

[2] scikit-learn. Common pitfalls and recommended practices.
https://scikit-learn.org/stable/common_pitfalls.html

[3] imbalanced-learn. Common pitfalls and recommended practices.
https://imbalanced-learn.org/stable/common_pitfalls.html

[4] scikit-learn. RobustScaler.
https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.RobustScaler.html

[5] imbalanced-learn. SMOTENC.
https://imbalanced-learn.org/stable/references/generated/imblearn.over_sampling.SMOTENC.html

[6] imbalanced-learn. Ensemble of samplers.
https://imbalanced-learn.org/stable/ensemble.html

[7] Gorishniy et al. Revisiting Deep Learning Models for Tabular Data.
https://arxiv.org/abs/2106.11959

[8] Arik & Pfister. TabNet: Attentive Interpretable Tabular Learning.
https://research.google/pubs/tabnet-attentive-interpretable-tabular-learning/

[9] Gorishniy et al. TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling.
https://arxiv.org/abs/2410.24210

[10] scikit-learn. Nested versus non-nested cross-validation.
https://scikit-learn.org/stable/auto_examples/model_selection/plot_nested_cross_validation_iris.html

[11] scikit-learn. average_precision_score.
https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html

[12] scikit-learn. Tuning the decision threshold for class prediction.
https://scikit-learn.org/stable/modules/classification_threshold.html

[13] scikit-learn. Probability calibration.
https://scikit-learn.org/stable/modules/calibration.html

[14] SHAP. TreeExplainer.
https://shap.readthedocs.io/en/latest/generated/shap.TreeExplainer.html

[15] SHAP. Be careful when interpreting predictive models in search of causal insights.
https://shap.readthedocs.io/en/latest/example_notebooks/overviews/Be%20careful%20when%20interpreting%20predictive%20models%20in%20search%20of%20causal%20insights.html